

Rapport Projet Analyse Données STA202

Analyse des ventes de maisons dans un département français

Tom Cuel, Ewerthon Melzani

March 8, 2025



Contents

Introduction	3
1 Description du projet et du dataset	3
2 Traitement des données	3
2.1 Analyse de la distribution et détection des valeurs aberrantes	3
2.2 Traitement des valeurs manquantes et normalisation	4
2.3 Suppression et réintégration des outliers pour l'exportation des données	4
3 Analyse descriptive des données	5
3.1 Visualisation des premières séries temporelles	5
3.2 Sélection des données modélisées pour le futur	5
4 Modélisation et extraction des tendances et saisonnalités	5
4.1 Moyenne mobile	6
4.2 Noyau gaussien	6
4.3 Polynômes locaux	7
4.4 Lissages exponentiels	8
4.4.1 Simple	8
4.4.2 Double	8
5 Prédiction des prix	9
5.1 Prédiction sur les données que l'on connaît	9
5.1.1 Modèle gaussien et polynômes locaux	9
5.1.2 Lissage exponentiel simple et double	9
5.2 Validation croisée des modèles	10
5.3 Prédiction à un horizon de temps donnée	10

Introduction

Ce document présente une analyse détaillée du dataset *Housing Prices France 35*, mis à disposition par l'utilisateur **cheneblanc** sur Kaggle. L'objectif est d'identifier les principaux facteurs influençant les prix immobiliers dans l'Ille-et-Vilaine, en exploitant des données de transactions et d'annonces en ligne, pour à terme effectuer des prédictions de prix.

1 Description du projet et du dataset

Le dataset *Housing Prices France 35* couvre le marché immobilier français dans le département des Ille-et-Vilaine et contient des informations clés sur les biens immobiliers :

- **Date** : Date de transaction.
- **Prix** : Valeur de transaction du bien.
- **Surface** : Surface habitable ou totale, exprimée en m².
- **Nombre de pièces** : Nombre of available parts in the home.
- **Localisation** : Ville, postal code, and GPS coordinates.
- **Caractéristiques supplémentaires** : Année de construction, type de bien (maison, appartement, etc.), coordonnées, ...

```
"date","position_wgs","x_lbt93","y_lbt93","category","area_living","area_land","n_rooms","shape_wgs","price"
"2020-09-16","POINT (-1.667233132948424 48.10518446058921)",352812.796361633,6788575.98852158,"C",30,0,1,"MULTIPOLYGON (((-1.667524599999999 48.104929699999998,
"2020-08-05","POINT (-1.580536596330411 48.15039836267523)",359546.007544795,6793214.56367109,"C",67,0,3,"MULTIPOLYGON (((-1.581126999999998 48.150120099999997,
```

Figure 1: Visualisation des headers du csv

Les données proviennent de sources variées telles que des transactions immobilières et des annonces en ligne, ce qui permet une analyse riche et diversifiée, chaque ligne présentant une donnée de vente. Voici un aperçu du résumé statistique des données :

```
> summary(df)
      date              position_wgs          x_lbt93          y_lbt93
Min.   :2014-01-02   Length:96748      Min.   :306757   Min.   :6739270
1st Qu.:2016-03-30   Class :character   1st Qu.:339444   1st Qu.:6786188
Median :2017-11-30   Mode  :character   Median :351109   Median :6789993
Mean   :2017-10-26   Mean   :350726   Mean   :6798904
3rd Qu.:2019-07-03   3rd Qu.:356182   3rd Qu.:6812465
Max.   :2020-12-31   Max.   :400278   Max.   :6855731

      category      area_living      area_land      n_rooms
Length:96748      Min.   : 9.00      Min.   : 0      Min.   : 1.000
Class :character   1st Qu.: 59.00      1st Qu.: 0      1st Qu.: 3.000
Mode  :character   Median : 80.00      Median : 276   Median : 4.000
Mean   : 86.05      Mean   : 1133   Mean   : 3.747
3rd Qu.:109.00      3rd Qu.: 692   3rd Qu.: 5.000
Max.   :667.00      Max.   :492529   Max.   :32.000

      shape_wgs      price      week      price_m2
Length:96748      Min.   : 1      Min.   :2013-12-29   Min.   : 0.0
Class :character   1st Qu.: 105000   1st Qu.:2016-03-27   1st Qu.: 737.9
Mode  :character   Median : 157500   Median :2017-11-26   Median : 1475.9
Mean   : 184726   Mean   :2017-10-22   Mean   : 1673.3
3rd Qu.: 227000   3rd Qu.:2019-06-30   3rd Qu.: 2356.3
Max.   :22200000   Max.   :2020-12-27   Max.   :341538.5

      area_total
Min.   : 10.0
1st Qu.: 64.0
Median : 129.6
Mean   : 256.1
3rd Qu.: 220.7
Max.   :74015.4
```

Figure 2: Résumé statistique des données


On remarque à travers ces premières données des prix moyens de biens aux alentours de 160 000€ (logique pour un département plutôt rural), des surfaces habitables moyennes de 86m² et des terrains de 1000m², et des biens avec en moyenne 4 pièces. Tout cela semble cohérent, au point près que on a quand même un prix de vente minimum de 1€ et un prix au m² de 0€, ce qui semble aberrant et qu'il faudra traiter.

2 Traitement des données

Le prétraitement des données est une étape essentielle pour garantir la qualité des analyses. Nous avons suivi les étapes suivantes :

2.1 Analyse de la distribution et détection des valeurs aberrantes


Afin de comprendre la distribution des prix, nous avons effectué un *boxplot* des données brutes. L'analyse a révélé une asymétrie importante :



Les quartiles 25% et 75% étaient particulièrement serrés avec tout de même une forte concentration de valeurs extrêmes au-dessus du 75^{ème} centile, ce qui est tout à fait normal, les biens immobiliers n'ayant pas des prix uniformes, et parfois très grand selon la taille et l'emplacement des propriétés. Nous avons donc étudié la distribution des prix après avoir supprimé les valeurs nulles. La visualisation suggère une distribution log-normale, que l'on a voulu confirmé par les tests suivants :

- **Test de Shapiro-Wilk** (limité à 5000 observations).
- **Test de Anderson-Darling** (plus robuste pour grands échantillons).

Les résultats ont rejeté l'hypothèse de normalité ($p\text{-value} = 2.2 \times 10^{-16}$). Nous avons donc appliqué une transformation logarithmique sur les prix afin de normaliser leur distribution. Nous avons ensuite enlever pour chaque catégorie (*price*, *area_living*, *area_land*) les valeurs aberrantes en utilisant la méthode de l'écart interquartile, on enlève les 1% des valeurs les plus extrêmes. On a alors :



2.2 Traitement des valeurs manquantes et normalisation

Nous avons identifié des valeurs manquantes dans les colonnes *n_rooms* et *price* (*Bien que le dataset n'en contienne pas au final, des précautions ont été prises sur ces points là*). Afin de les imputer de manière pertinente, nous avons calculé la corrélation entre les variables :

- **Surface habitable** montre une forte corrélation avec *n_rooms* et *price*.
- Pour **price**, la corrélation avec *area_living* et *n_rooms* est modérée ($r \approx 0.4$).

Nous avons testé plusieurs modèles de régression linéaire avec 2, 3 et 4 variables explicatives. Le modèle offrant le meilleur score a été retenu pour imputer les valeurs manquantes.

2.3 Suppression et réintégration des outliers pour l'exportation des données

Comme le dataset présentait une forte *skewness*, nous avons appliqué une **suppression des outliers basée sur les quantiles des valeurs logarithmiques**. Une fois l'**imputation des valeurs manquantes** via *régression linéaire multiple* terminée, nous avons **réintégré les valeurs extrêmes** (*bien que l'on réintègre la maison à 1€ ou au prix au m² de 0€*) avec `anti_join` et `bind_row` car elles peuvent représenter des tendances particulières du marché. On **vérifie** ensuite qu'on n'a pas de doublons et sinon on les supprime avec `df <- df %>% distinct()`, et on peut **valider la transformation des données** pour assurer la validé des analyses futures. Et finalement, on exporte le dataset nettoyé dans

```
write.csv(df, "house_prices_france_cleaned.csv", row.names = FALSE)
```

Ce dataset est désormais prêt pour des analyses approfondies ou des modèles de prédiction des prix immobiliers.


3 Analyse descriptive des données

3.1 Visualisation des premières séries temporelles


Plusieurs données nous intéressent. Nous avons premièrement visualisé les différents paramètres en fonction du temps, pour voir si des tendances se dégagent à l'oeil nu. On a aussi ajouté de simples régressions linéaires pour voir les tendances générales des données de manière plus mathématique.

On voit aussi plusieurs phénomènes qui se manifestent :


- **Les prix de vente** ont tendance à augmenter, ce qui est normal avec l'inflation et la hausse des prix de l'immobilier.
- **Les prix au m²** ont tendance à augmenter, ce qui est aussi normal avec l'augmentation des prix de vente.
- **Le nombre de ventes** a tendance à augmenter, ce qui est aussi normal avec l'augmentation de la population et de la demande, même si l'on peut bien voir l'effet du Covid-19 sur les ventes en début 2020.
- **La taille des biens** reste la même, ce qui est normal, les biens ne peuvent pas tant changer de taille.
- Au global, **les prix totaux** augmentent, ce qui est normal avec l'augmentation des prix de vente et du nombre de ventes, et traduit bien la tendance d'un marché en expansion.
- Il semble y avoir une **saisonnalité** dans les données, avec des pics de ventes en été et des creux en hiver, que l'on verra mieux au moment de détacher les tendances et saisonnalités.




(a) Total des prix de ventes




(b) Prix des biens



(a) Prix au m²



(b) Taille des biens



(c) Nombre de ventes

3.2 Sélection des données modélisées pour le futur

Après ces premières analyses, on va sélectionner seulement quelques données à modéliser pour le futur :

- Comme la surface des biens reste la même, l'augmentation du prix au m² est équivalent à l'augmentation du prix des biens, on va donc se concentrer sur les **prix des biens** pour les modélisations.
- On va aussi se concentrer sur les **prix total des ventes**, qui prend en compte les différentes tendances du marché, incluant à la fois le prix des biens et le nombre de ventes. On aurait pu se concentrer sur le nombre de ventes mais cela ne nous semblait pas forcément plus pertinent.

4 Modélisation et extraction des tendances et saisonnalités

Les données vont dans un premier temps être modélisées selon différents modèles pour trouver les tendances et saisonnalités des données. On va utiliser les modèles suivants, où l'on va extraire par moyenne mobile des données sur les prix totaux et les prix des biens tandis que les autres modèles vont seulement s'occuper du prix total car c'est ce que l'on prédira plus tard.

4.1 Moyenne mobile

Le lissage par moyenne mobile est une méthode simple pour extraire les tendances et saisonnalités des données. On va utiliser une moyenne mobile prenant en compte les 40 dernières observations pour extraire la tendance et une moyenne mobile prenant en compte les 10 dernières observations pour extraire la saisonnalité.




Figure 7: Tendence et saisonnalité des prix totaux par moyenne mobile

On voit ici bien cette tendance à la hausse des prix totaux de ventes en général, ainsi que la dépendance en terme de ventes selon la saison de l'année. En effet, en été il semble y avoir plus de transactions, tandis qu'en hiver il y en a moins, avec aussi l'influence du covid dans la saisonnalité.




Figure 8: Tendence et saisonnalité des prix des biens par moyenne mobile

On voit ici bien cette tendance à la hausse des prix des biens en général, plus accentuée en 2020 qu'en 2016, ainsi que la dépendance en terme de prix de ventes selon la saison de l'année. Cela peut sembler normal que les maisons se vendent en général plus cher en été, il y a plus de lumière pour faire ressortir la beauté des propriétés, et les gens sont plus enclins à acheter en été et sûrement plus cher qu'en hiver où ils seront plus réticents.

4.2 Noyau gaussien

On effectue la même chose pour un noyau gaussien de paramètre $h = 1000$ pour la tendance et $h = 100$ pour la saisonnalité mais seulement sur le prix total maintenant, les analyses pour le prix des biens ayant les mêmes méthodes mais peut-être moins d'analyse, et on obtient des résultats similaires (*un h plus grand permettra un plus grand lissage*) :




Figure 9: Tendence et saisonnalité des prix totaux par noyau gaussien

On cherche aussi à regarder l'autocorrélation de la modélisation avec les données




Figure 10: Autocorrélation des prix totaux par noyau gaussien

On voit qu'il y a une forte autocorrélation au lag 0 (*normal, car un résidu est toujours parfaitement corrélé avec lui-même*). Aux autres lags, la plupart des barres restent à l'intérieur des bandes de confiance, ce qui suggère que les résidus sont globalement non corrélés. Quelques valeurs dépassent légèrement les bandes bleues, ce qui peut indiquer une autocorrélation résiduelle faible à certains lags, mais cela peut être dû à des fluctuations aléatoires dans les données. Si les résidus étaient totalement indépendants, toutes les barres devraient rester dans les bandes bleues. Ici, la présence de quelques valeurs marginalement significatives n'indique pas nécessairement un gros problème, mais si elles formaient un motif récurrent, cela suggérerait que la décomposition par noyau gaussien ne capture pas totalement la structure temporelle des données.

4.3 Polynômes locaux

Et de même pour une modélisation par polynômes locaux :




Figure 11: Tendence et saisonnalité des prix totaux par polynômes locaux




Figure 12: Autocorrélation des prix totaux par polynômes locaux

On voit que comme dans le premier graphe, l'autocorrélation est maximale à lag 0 (normal). Concernant l'autocorrélation aux autres lags, globalement, la plupart des valeurs restent dans les bandes de confiance (lignes bleues). Comparé au modèle à noyau gaussien, il y a encore moins d'autocorrélation résiduelle, ce qui peut indiquer une meilleure modélisation des tendances sous-jacentes. Les valeurs qui dépassent légèrement les bandes sont moins fréquentes que dans le modèle précédent.

4.4 Lissages exponentiels

Plutôt que de toujours extraire la tendance et la saisonnalité dans nos modèles, on va aussi modéliser les données avec des lissages exponentiels, ici on ne va s'intéresser qu'aux prix totaux car ce sera les seuls que l'on va prédire par la suite.

4.4.1 Simple

Ce lissage possède un paramètre α qui contrôle l'importance des observations passées.






Figure 13: Lissage exponentiel simple avec $\alpha = 0.1$

On cherche ensuite le meilleur α pour le lissage exponentiel simple, celui qui minimise l'erreur de prédiction, et on voit sur les résultats suivants que cela colle bien avec les données :




(a) Erreurs en fonction de α




(b) Meilleur $\alpha = 0.3$

4.4.2 Double

On fait de même pour le lissage exponentiel double, qui possède aussi le paramètre α qui contrôle l'importance des observations passées et des tendances passées.



(a) Erreurs en fonction de α




(b) Meilleur $\alpha = 0.2$

5 Prédiction des prix


Pour la prédiction des prix, on va uniquement s'intéresser au marché, avec les prix totaux. On ne va pas considérer la moyenne mobile, il manque en effet dans les modèles les points au début et à la fin, pour ne pas compliquer les choses à devoir rajouter des points, on va se concentrer sur les modèles de noyau gaussien, polynômes locaux et lissages exponentiels.

5.1 Prédiction sur les données que l'on connaît

Cela sera sur la partie en rouge, les données que l'on connaît, pour voir si les modèles collent bien avec les données que l'on a déjà.




5.1.1 Modèle gaussien et polynômes locaux



Les polynômes locaux (*orange*) semblent mieux coller avec les données que le noyau gaussien (*bleu*) sur les intervalles de confiance, qui pense même que l'on peut vendre des maisons avec des prix négatifs.

5.1.2 Lissage exponentiel simple et double


Ces modèles (*simple et double*) vont faire de la prédiction à un horizon de temps donné, mais très simple, avec seulement une valeur constante pour le lissage exponentiel simple et une droite pour le lissage exponentiel double. On trace tout de même les intervalles de confiance à 97,5% pour voir la fiabilité de la prédiction.



On peut voir qu'on est plutôt proche des données pour l'exponentielle double et un peu plus loin pour l'exponentielle simple.

5.2 Validation croisée des modèles

Voici un exemple de test de validation croisée pour le modèle de gaussienne, qui ne suit pas vraiment nos données montrant de certains manques dans la modélisation :



Dans toutes les configurations testées, seul celle de la validation croisée pour le modèle de lissage exponentiel simple nous donne un résultat, qui nous semble aberrant. $10e^{14}$ d'erreur quadratique, pour 50-100 semaines de prédiction en validation croisée, alors qu'à la semaine, on a au maximum 10^8 de ventes totales, multiplié par 100 semaines, cela nous donne 10^{10} , ce qui est bien loin de 10^{14} pour la Mean Square Error (*MSE*).

5.3 Prédiction à un horizon de temps donnée

Nous allons prédire l'évolution des données à un horizon de temps donné de 1 an pour simuler la progression du marché, après avoir tester et valider nos modèles à l'étape précédente. Voici les résultats obtenus




Figure 16: Prédiction à 1 an

On peut voir que pour les différents modèles, les prédictions prévoient une baisse de la somme vendue totale. Nous pensons que cela est dû à l'influence d'un épisode très rare qu'est le Covid 19, qui ne reflète pas la tendance réelle d'un marché en augmentation, mais qui pour les données n'est pas un événement aussi exceptionnel et non significatif. La prédiction n'est dans ce cas pas extrêmement fiable, mais elle reste tout de même cohérente avec les données que l'on lui présente.